

DATOS MASIVOS I

UNIDAD IV ALGORITMOS PARA FLUJOS DE DATOS


MUESTREO Y FILTRADO

15 de Marzo de 2023

- En muchos casos no es posible almacenar todos los datos de un flujo, por lo que es necesario realizar muestreo.

Muestreo en flujos de datos

- Objetivo: seleccionar un subconjunto de datos del flujo de tal manera que sean representativas de todo el flujo de datos.



Ventaja

- Costo computacional más bajo debido a que estamos usando solo una porción del flujo.

Retos

- ¿Cómo sabemos qué tan largo es el flujo de datos?
- ¿Cada cuánto tiempo debemos muestrear?
- ¿Cómo hacemos el muestreo?

Estrategias de muestreo

- Ventanas deslizantes

- Muestreo aleatorio

- Muestreo de tamaño fijo

Ventanas deslizantes




Las consultas se realizan sobre una ventana de tamaño w .



Si un elemento llega en el tiempo t , expira en el tiempo $t + w$.

Ventanas deslizantes



Ventanas deslizantes

- En este ejemplo el tamaño de la ventana deslizante es 6.

q w e r t y u i o p **a s d f g h** j k l z x c v b n m

q w e r t y u i o p a **s d f g h j** k l z x c v b n m

q w e r t y u i o p a s **d f g h j k** l z x c v b n m

q w e r t y u i o p a s d **f g h j k l** z x c v b n m

← **Past** **Future** →

Promedio de ventana deslizante

Calificaciones

10.0	7.8	6.8	8.0	9.2	9.0
------	-----	-----	-----	-----	-----

Definir:

- Tamaño de la ventana: 3

Promedio de ventana deslizante

Calificaciones

Tamaño de la ventana: 3

10.0	7.8	6.8	8.0	9.2	9.0
------	-----	-----	-----	-----	-----

$\text{suma_ventana} = (10 + 7.8 + 6.8) / 3$
 $\text{resultado} = 8.2$

Secuencia resultante: [8.2]

Promedio de ventana deslizante

Calificaciones

Tamaño de la ventana: 3

10.0	7.8	6.8	8.0	9.2	9.0
------	-----	-----	-----	-----	-----

$\text{suma_ventana} = (7.8 + 6.8 + 8.0) / 3$
 $\text{resultado} = 7.53$

Secuencia resultante: [8.2, 7.53]

Promedio de ventana deslizante

Calificaciones

Tamaño de la ventana: 3

10.0	7.8	6.8	8.0	9.2	9.0
------	-----	-----	-----	-----	-----

$\text{suma_ventana} = (6.8 + 8.0 + 9.2) / 3$
 $\text{resultado} = 8$

Secuencia resultante: [8.2, 7.43, 8,]

Promedio de ventana deslizante

Calificaciones

Tamaño de la ventana: 3

10.0	7.8	6.8	8.0	9.2	9.0
------	-----	-----	-----	-----	-----


$\text{suma_ventana} = (8.0 + 9.2 + 9.0) / 3$
 $\text{resultado} = 8.73$

Secuencia resultante: [8.2, 7.43, 7.96, 8.73]

Ventanas de salto de tamaño constante

Se divide el flujo de datos en segmentos de tiempo sin traslape.

Tell me the count of tweets per time zone every 10 seconds




```
SELECT TimeZone, COUNT(*) AS Count
FROM TwitterStream TIMESTAMP BY CreatedAt
GROUP BY TimeZone, TumblingWindow(second,10)
```

- Agrupan eventos que llegan en tiempos similares, filtrando los periodos en los que no se recibe ningún dato.
- Los parámetros de este tipo de ventana son el tiempo de espera y duración máxima.

Ventanas de sesión

Tell me the count of tweets that occur within 5 minutes to each other.



```
SELECT Topic, COUNT(*)  
FROM TwitterStream TIMESTAMP BY CreatedAt  
GROUP BY Topic, SessionWindow(minute, 5, 10)
```

Imagen tomada de Azure Stream Analytics

Muestreo.

- Los elementos tienen la misma probabilidad de ser seleccionados.


- Ejemplo: Cobertura de la vacuna anti-sarampión entre 1,200 niños de la escuela 'Juan Escutia':
 - Muestra: 60 niños
 - Hacer una lista de todos los niños
 - Numerarlos del 1 al 1,200
 - Selección aleatoria de 60 números (probabilidad igual)

- Los elementos se seleccionan en base a criterios o reglas específicas.

- Ejemplo: únicamente se registrarán a los pacientes que acudan a la clínica en cierto día u horario particular.
- Es posible que los elementos seleccionados sean poco representativos de todos los conjuntos generados.

Muestreo de tamaño fijo

Consiste en muestrear una porción fija de los elementos recibidos (digamos 1 de cada 10 recibidos)

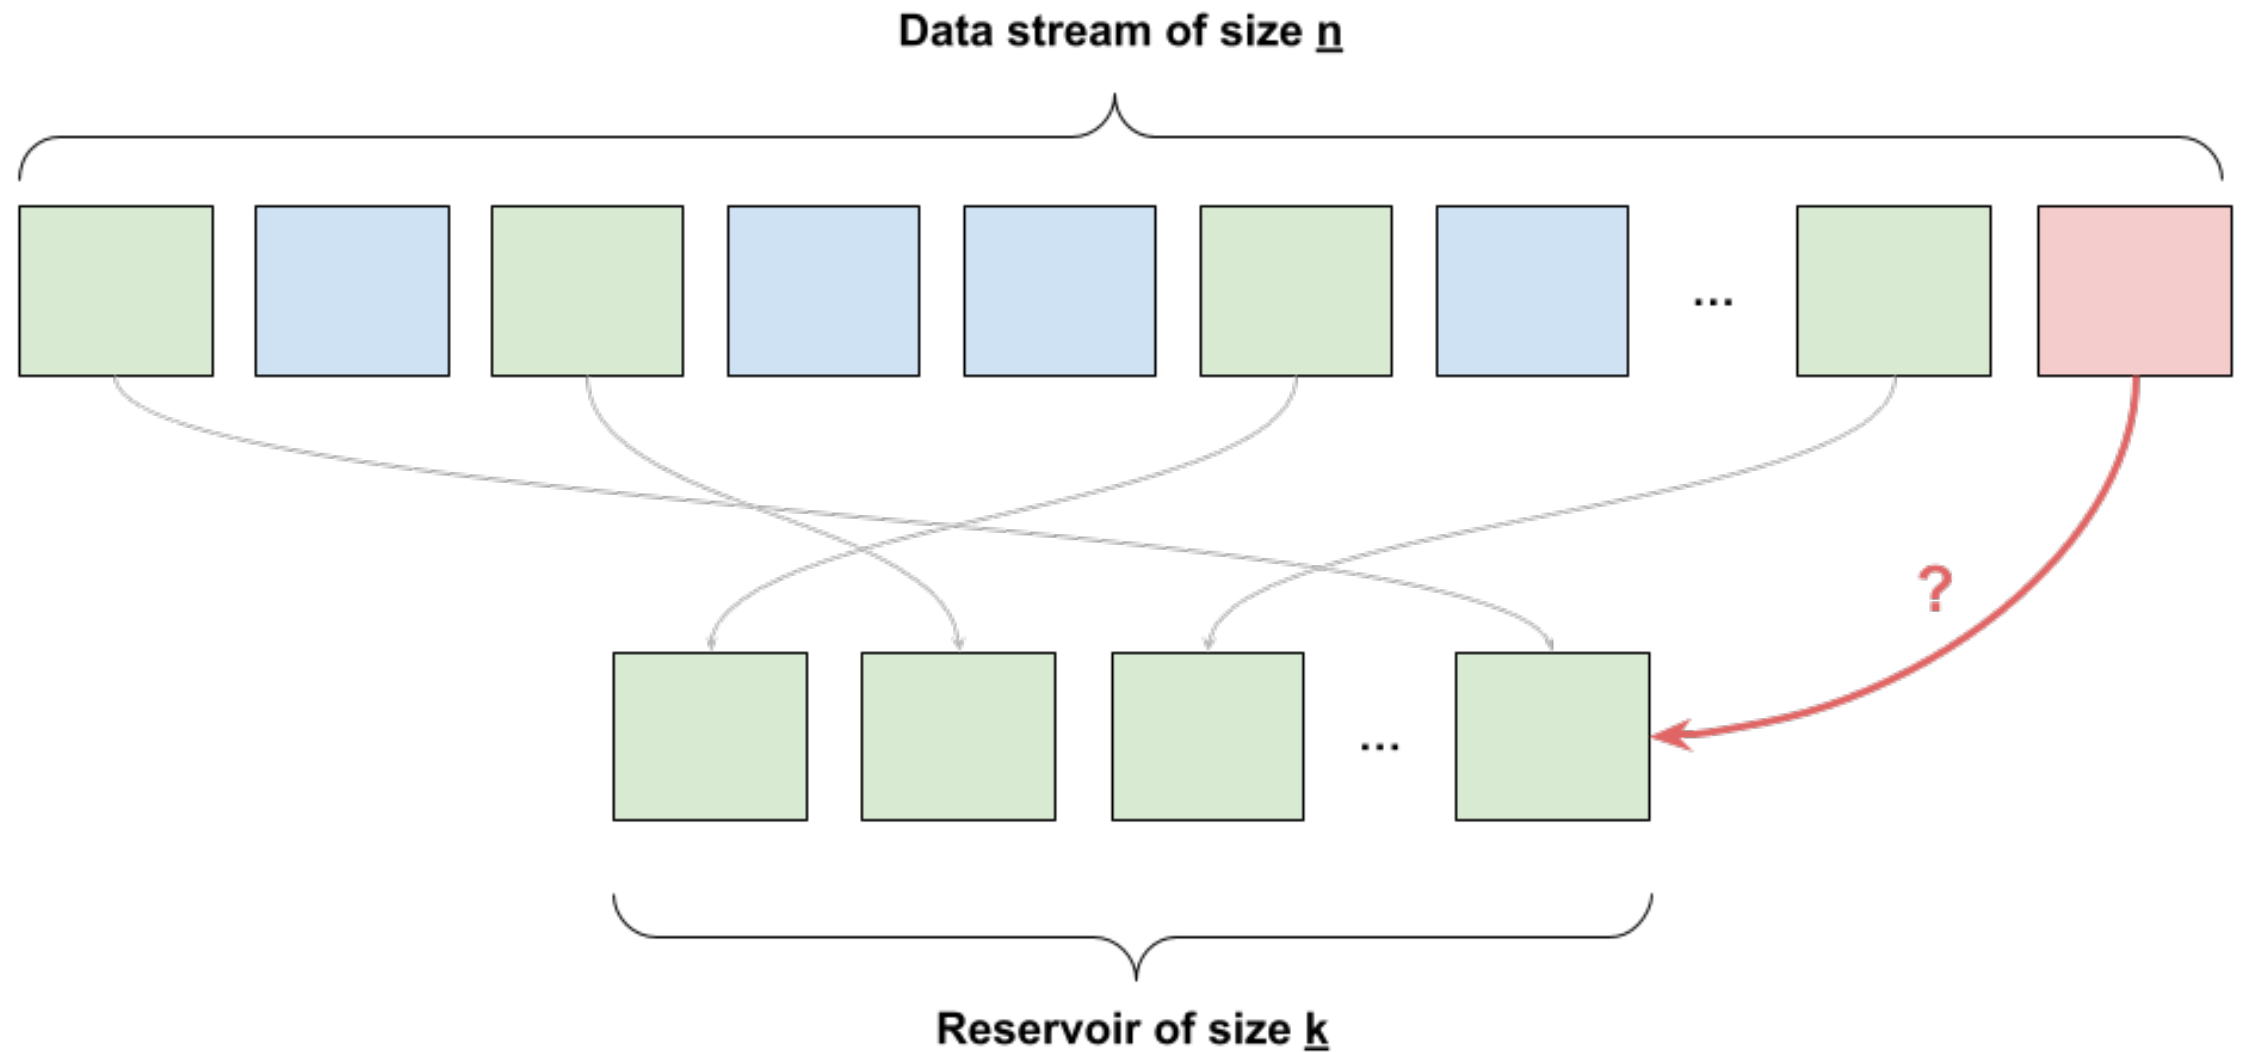


- Como observamos hacer el muestreo tomando una muestra de cada usuario, puede arrojar resultados poco confiables.


Muestreo de presa (Reservoir sampling)

- Consiste en muestrear los primeros m datos recibidos y los mantiene en memoria (presa).
- Cada nuevo elemento recibido tiene una probabilidad $\frac{m}{n}$ de reemplazar un elemento actual.

Muestreo de presa (Reservoir sampling)



Muestreo de presa (Reservoir sampling)



- Procedimiento general

1. Toma los primeros k elementos del flujo como muestra.

2. Supongamos que hemos visto $n - 1$ elementos, y ahora recibimos el n -ésimo elemento ($n > k$).

3. Con probabilidad $\frac{k}{n}$, mantenemos el elemento n -ésimo, reemplazando uno de los k elementos en la muestra.

- Seleccionar elementos del flujo que cumplan cierto criterio y descartar el resto.
- Ejemplo: dado un flujo de números reales, filtrar los que sean mayores a 50.

Ejemplo: dado un flujo de números reales, filtrar los que sean mayores a 50.

- Flujo: 33, 71, 58, 12, 41, 56, 3, 89.
- Elementos seleccionados: 71, 58, 56, 89.

- Esta tarea se vuelve más difícil cuando el criterio requiere verificar si el elemento pertenece a un conjunto dado, especialmente si este conjunto es tan grande que no cabe en memoria

Pertenencia a un conjunto: Ejemplo

- ¿Cómo podemos revisar rápidamente la disponibilidad de un nombre dentro de cientos de millones existentes?



Create your Google Account

Continue to Gmail

First name

random

Last name

random

Username

JonhSmith

@gmail.com

! That username is taken. Try another.

Password

••••••••

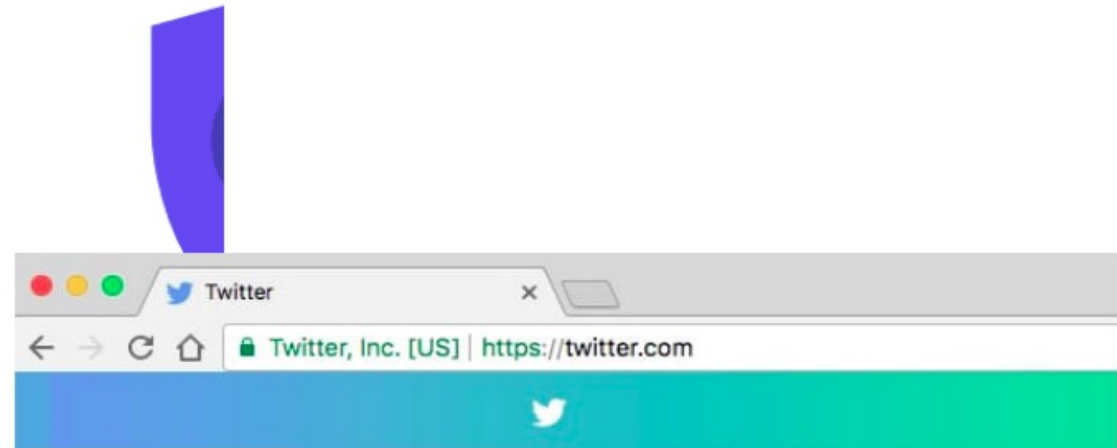
Confirm

••••••••



[Sign in instead](#)

Next



Choose a username.

Don't worry, you can always change it later.

follows

✗ This username is already taken!

Búsqueda binaria

- Supongamos que almacenamos todos los nombres alfabéticamente y comparamos el nuevo nombre con el que aparece a mitad de la lista.
- Si el nombre coincide, devuelve intentar nuevamente.

Búsqueda binaria

- En caso contrario, busca nuevamente en la mitad de los nombres restantes (arriba - abajo).
- Se repite el proceso, hasta que encuentre una coincidencia o hasta que termina la búsqueda y no encuentre nada.

- Es una estructura de datos probabilista y se emplea para evaluar si un elemento pertenece a un conjunto.
- Elimina la mayoría de los elementos que no pertenecen al conjunto.

- Pro: Es muy eficiente en memoria, ya que no requiere mantener el conjunto en memoria.
- Contra: Tiene falso positivos.

Fue desarrollado por Burton Howard Bloom en 1970.

- Consiste en un arreglo de m bits inicializados con 0.

Construcción.

1. Para cada elemento s del conjunto de cardinalidad c , se calculan los valores *hash* con k funciones distintas $h_1(s), h_2(s), \dots, h_k(s)$.

2. Los k bits en las posiciones correspondientes a los k valores *hash* se le asigna *1*.


Verificación de pertenencia de un nuevo elemento:

1. Calcula los valores *hash* para \tilde{s} : $h_1(\tilde{s})$, $h_2(\tilde{s}), \dots, h_k(\tilde{s})$
2. Si todos los bits en las posiciones correspondientes a los k valores *hash* son 1, entonces es probable que el elemento \tilde{s} pertenezca al conjunto, en caso contrario definitivamente no pertenece.

Estructura del filtro de Bloom

Estructura de un filtro de Bloom

Cada celda vacía representa un bit



Filtro de Bloom vacío

Filtro de Bloom vacío: es un vector de m bits donde todos los valores son ceros.



- ¿Cómo llenamos un filtro de Bloom?

Para añadir un elemento x al filtro S :

- x debe transformarse a un conjunto de bits a través de k funciones *hash*. El resultado de cada función indica el índice dentro del filtro, que debe cambiarse de 0 a 1.

Definiendo M , N y K

Filtro de
Bloom vacío



Antes de empezar debemos definir:

- m = tamaño del vector (número de bits)
- n = número de elementos agregar
- k = número de funciones hash




- $m = 10$
- $n = 2$
- $k = 3$

Definiendo M , N y K

- Añadir al filtro el nombre de usuario: *'ironman'*
 1. Calculamos las funciones hash, la salida será el índice que debemos cambiar a 1.

```
(mat_datmas) blanca@blanca-G7-7588:~/Desktop/virtualEnvironment/mat_datmas$  
Python 3.6.9 (default, Nov 7 2019, 10:44:02)  
[GCC 8.3.0] on linux  
Type "help", "copyright", "credits" or "license" for more information.  
>>> import mmh3  
>>> mmh3.hash('ironman',1) % 10  
4  
>>> mmh3.hash('ironman',2) % 10  
1  
>>> mmh3.hash('ironman',3) % 10  
6
```

2. Colocamos '1' en cada bit, usando el resultado de la función hash.

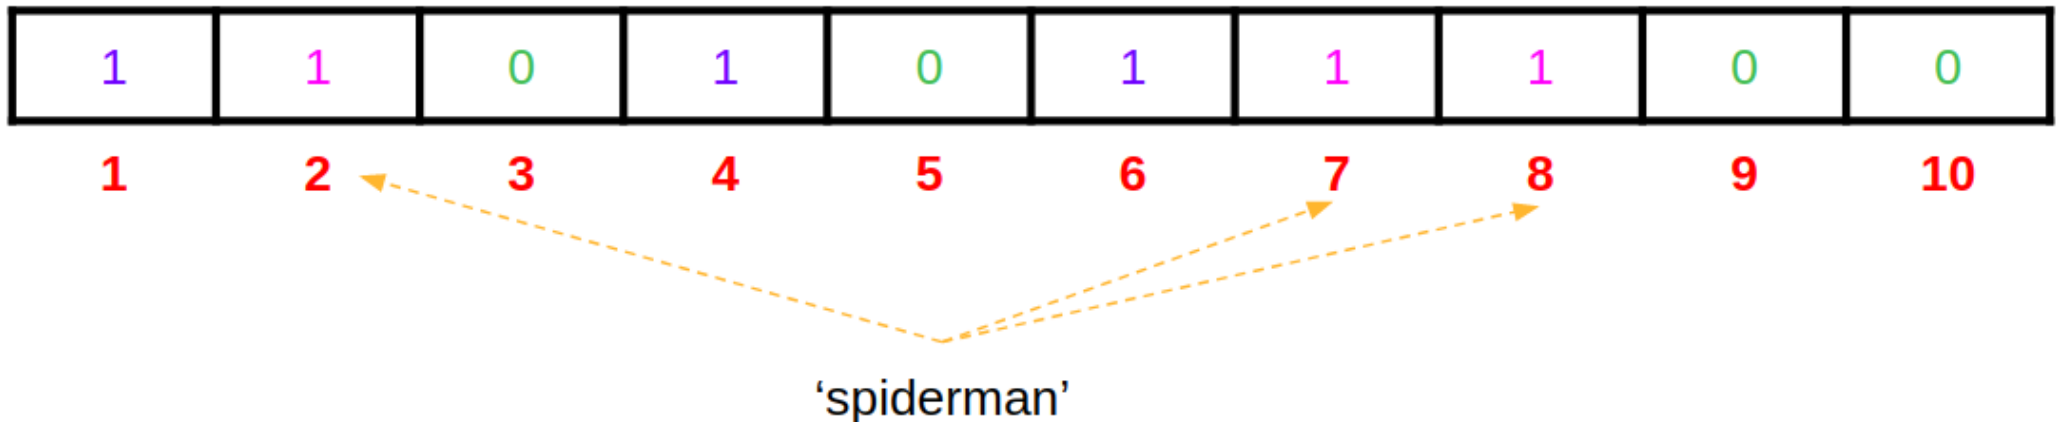


Definiendo M , N y K

- Añadir al filtro el nombre de usuario: *'spiderman'*
 1. Calculamos las funciones hash, la salida será el índice que debemos cambiar a 1.

```
>>> mmh3.hash('spiderman',1) % 10
2
>>> mmh3.hash('spiderman',2) % 10
8
>>> mmh3.hash('spiderman',3) % 10
7
>>> 
```

2. Colocamos '1' en cada bit, usando el resultado de la función hash.




Buscando en el filtro

Lo más importante de un filtro de Bloom es buscar un elemento dentro del vector S

- Buscar si en S existe: *'ironman'*
 1. Calculamos las funciones hash, la salida será el índice que debemos cambiar a 1.

```
>>> mmh3.hash('ironman',1) % 10  
4  
>>> mmh3.hash('ironman',2) % 10  
1  
>>> mmh3.hash('ironman',3) % 10  
6
```



Si todos los índices (arrojados de la función hash) son 1s, entonces decimos que: *'ironman'* *probablemente* están presente en S


Buscando en el filtro

Lo más importante de un filtro de Bloom es buscar un elemento dentro del vector S

- Buscar si en S existe: *'thanos'*

1. Calculamos las funciones hash, la salida será el índice que debemos cambiar a 1.

```
>>> mmh3.hash('thanos',1) % 10  
7  
>>> mmh3.hash('thanos',2) % 10  
8  
>>> mmh3.hash('thanos',3) % 10  
6
```



Si todos los índices (arrojados de la función hash) son 1s, entonces decimos que: *'thanos' probablemente están presente en S*

Buscando en el filtro

Lo más importante de un filtro de Bloom es buscar un elemento dentro del vector S


- Buscar si en S existe: *'thanos'*

1. Calculamos las funciones hash, la salida será el índice que debemos cambiar a 1.

```
>>> mmh3.hash('thanos',1) % 10
7
>>> mmh3.hash('thanos',2) % 10
8
>>> mmh3.hash('thanos',3) % 10
6
```

1	1	0	1		1	1	1	0	0
1	2	3		5	6	7	8	9	10

Falso positivo



Si todos los índices (arrojados de la función hash) son 1s, entonces decimos que: *'thanos' probablemente están presente en S*

- Dependiendo de la aplicación, un falso positivo puede representar un gran problema o simplemente puede mantenerse.

¿Cómo evitar o reducir los falsos positivos?

¿Cómo evitar o reducir los falsos positivos?

- Más espacio. Incrementar el tamaño del vector.
- Incrementar el número de k (funciones *hash*).

Selección de funciones hash

Las funciones hash usadas en el filtrado de Bloom deben ser:

- Independientes
- Uniformemente distribuidas (dado un conjunto de valores, cada valor tiene la misma probabilidad de suceder).
- Deben de ser rápidas (para su cálculo)
- No criptográficas (las funciones criptográficas son más estables, pero son costosas para calcularlas).

Cuando el número de funciones hash incrementa, el filtrado se vuelve lento. Ejemplos de funciones con bajas tasas de colisiones y no criptográficas:

- **MURMUR**: multiplicar (MU), rotar (R), multiplicar (MU), rotar (R) (2011)
- **FNV**: Fowler/ Noll/ Vo, es un indexador rápido (1991)
- **Jenkins** o HashMix (1997)

Falsos positivos: Probabilidad

- La probabilidad de que 1 bit no sea puesto a 1 durante el registro de un elemento es

$$1 - \frac{1}{m}$$

- Para k funciones *hash* esto es

$$\left(1 - \frac{1}{m}\right)^k$$

- Usando la identidad de e^{-1}

$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^k = \frac{1}{e}$$

- Esto es, cuando m es muy grande

$$\left(1 - \frac{1}{m}\right)^k = \left(\left[1 - \frac{1}{m}\right]^m\right)^{\frac{k}{m}} \approx e^{-\frac{k}{m}}$$

Falsos positivos: Probabilidad

- Si ya han sido registrados n elementos en el arreglo de bits, la probabilidad de un bit dado esté en 0 es

$$\left(1 - \frac{1}{m}\right)^{k \cdot n} \approx e^{-\frac{k \cdot n}{m}}$$

- La probabilidad de que ese bit esté en 1 es

$$1 - \left(1 - \frac{1}{m}\right)^{k \cdot n} \approx 1 - e^{-\frac{k \cdot n}{m}}$$

- Para que exista un falso positivo, todos los bits de las k funciones *hash* deben estar en 1 y la probabilidad de que esto ocurra es

$$\left(1 - \left[1 - \frac{1}{m}\right]^{k \cdot n}\right)^k \approx \left(1 - e^{-\frac{k \cdot n}{m}}\right)^k$$

- Medium usa filtros de Bloom para recomendar publicaciones a los usuarios, filtrando las publicaciones que ya ha visto el usuario.

- Quora filtra historias no vistas.

- Google Chrome usó filtros de Bloom para detectar *URLs* maliciosas.